

SBB Tracker — Pünktlichkeitsanalyse der Schweizerischen Bundesbahnen

Scientific Programming · FS2026 Joël Hasler & Patrick Ferreira

Datum: 27. Mai 2026 **Modul:** Scientific Programming, ZHAW **Dozent:** Mario Gellrich **GitHub:** <https://github.com/Mrgincinamon/SBB-Tracking>

1. Einleitung

1.1 Hintergrund

Die Schweiz hat eines der dichtesten und pünktlichsten Bahnnetze der Welt. Die Schweizerischen Bundesbahnen (SBB) befördern täglich rund 1.3 Millionen Passagiere und führen über 11'000 Zugfahrten durch. Die offizielle Kundenpünktlichkeit lag 2024 bei 92.5 % — international ein Spitzenwert, aber für eingefleischte Pendler dennoch spürbar verbesserenswert.

Seit Juni 2016 publiziert das Bundesamt für Verkehr (BAV) zusammen mit der Geschäftsstelle KIM die **Ist-Daten** als Open Data: pro Tag eine CSV mit allen Soll-/Ist-Vergleichen jedes Zug-Halts in der Schweiz. Diese Datenmenge (rund 2.5 Millionen Records pro Tag, knapp 500 MB) erlaubt erstmals eine unabhängige, statistisch saubere Analyse der Pünktlichkeit auf Stations-, Linien- und Stundenbasis.

1.2 Problemstellung

Trotz der reichen Datenbasis ist es für einzelne Pendler schwierig, konkrete Antworten auf relevante Alltags-Fragen zu finden:

- Sind Züge am Wochenende wirklich pünktlicher als an Werktagen?
- Welche Bahnhöfe sind Verspätungs-Hotspots?
- Wie stark beeinflusst das Wetter (insbesondere Niederschlag) die Pünktlichkeit?
- Welche Tageszeit ist am riskantesten für termingebundene Reisen?

Bestehende SBB-Statistiken sind Monats-Aggregate ohne Stationsdetail. Die offizielle Pünktlichkeitsangabe „92.5 %“ ist für die individuelle Reiseplanung zu grob.

1.3 Zielsetzung

Dieses Projekt baut eine **End-to-End-Datenpipeline** vom Rohdaten-Download über die SQL-Datenbank zur statistischen Analyse und schliesslich zu einer interaktiven Webapp:

1. **Datenpipeline:** Automatisierter Download von SBB-Ist-Daten + Wetter + Stationen, gefiltert, in SQLite gespeichert.
2. **Statistische Analyse:** Vier Hypothesen-Tests mit p-Value-Reporting (t-Test, ANOVA, Korrelation, multivariate OLS-Regression).
3. **Visualisierung:** Heatmaps, Karten, Verteilungs-Plots nach Best Practice.
4. **Interaktive Webapp:** Streamlit + Folium mit LLM-gestütztem Pendler-Insight.

1.4 Forschungsfragen

1. **H1 (Werktag-Effekt):** Unterscheidet sich die mittlere Verspätung zwischen Werktagen und Wochenende signifikant?
 2. **H2 (Zugtyp-Effekt):** Beeinflusst der Linien-Typ (S-Bahn, IC, IR, RE) die Verspätungsverteilung?
 3. **H3 (Wetter-Korrelation):** Korreliert Niederschlag oder Temperatur mit der Verspätung?
 4. **H4 (Multivariate Erklärung):** Welche Faktoren erklären Verspätung gemeinsam in einem linearen Modell?
-

2. Material und Methoden

2.1 Datenquellen

Datensatz	Quelle	Umfang	Format
Ist-Daten	opentransportdata.swiss (CKAN-Dataset <code>istdaten</code>)	48 Tage, 31. März – 19. Mai 2026 (~3.2 Mio SBB-Zug-Events)	CSV → Parquet
Stationen	data.sbb.ch (Dienststellen-Datensatz)	1'743 aktive Bahnhöfe mit Geo-Koordinaten	CSV
Wetter	MeteoSchweiz Open Data (<code>ch.meteoschweiz.ogd-smn</code>)	15 Stationen, stündlich, ~3'336 h pro Station	CSV → Parquet

Alle Datensätze sind öffentlich (CC-BY-Lizenz, kein API-Key nötig).

2.2 Datenaufbereitung (Notebook 02)

- **Filter:** Nur `produkt_id == 'Zug'` und `betreiber_abk == 'SBB'` (~3 % der Roh-Records); Roh-CSVs nach Filterung gelöscht (Disk-Effizienz).
- **REAL-Filter:** Nur `an_prognose_status == 'REAL'` (echte Messungen, 86 %).
- **Zeit-Features:** Stunde, Wochentag, Wochenende-Flag, Rush-Hour-Flag.
- **Wetter-Join:** Pro Bahnhof nächste Wetterstation via `scipy.spatial.cKDTree` (Euklidisch auf lat/lon); Merge auf (`weather_station`, `stunde`).
- **Klassifikation:** Verspätungen in 7 Buckets von "frueh_30+s" bis

"extrem_ueber_10min"; binäre Spalte `is_late_3min` (SBB-Definition >3 Min).

2.3 Statistische Methoden (Notebook 03)

Test	Anwendung	scipy/statsmodels-Funktion
Welch's t-Test	Werktag vs. Wochenende	<code>scipy.stats.ttest_ind(..., equal_var=False)</code>
Mann-Whitney-U	Verteilungsfreier Cross-Check zu t-Test	<code>scipy.stats.mannwhitneyu</code>
Einweg-ANOVA	Verspätung nach Linientyp (top 5)	<code>scipy.stats.f_oneway</code>
Pearson-Korrelation	Linear: Wetter ↔ Verspätung	<code>scipy.stats.pearsonr</code>
Spearman-Korrelation	Monoton: Wetter ↔ Verspätung	<code>scipy.stats.spearmanr</code>
Multiple OLS-Regression	Multivariates Erklärungsmodell	<code>statsmodels.formula.api.ols</code>

Signifikanzschwelle $\alpha = 0.05$. Bei multiplen Tests könnte eine Bonferroni-Korrektur auf $\alpha = 0.0125$ ($k = 4$) angewendet werden — wir berichten p-Werte unkorrigiert, da die Effekte deutlich signifikant sind.

2.4 LLM-Integration (Notebook 04 + Webapp)

Anthropic Claude Sonnet 4.6 wird in zwei Kontexten eingesetzt:

1. **Notebook 04**: Qualitative Klassifikation der Top-10 Krisen-Tage. Pro Tag wird ein Kontext-JSON (top betroffene Bahnhöfe, Wetterzusammenfassung, Tageszeit-Pattern) an das Modell übergeben mit fester Taxonomie möglicher Ursachen. Temperatur 0.2 für Reproduzierbarkeit.
2. **Webapp** (Tab "Pender-Insight"): Freie Frage-Antwort-Funktion. Das Modell erhält statistischen Datenkontext aus dem aktuellen Datensatz und antwortet kurz und auf deutsch.

API-Key wird über `.env`-Datei und `python-dotenv` geladen (gitignored).

2.5 Tech-Stack

- **Python 3.12** (kursvorgegeben)
- **pandas / numpy / scipy / statsmodels** — Data + Statistik
- **matplotlib / seaborn / plotly** — Visualisierungen
- **sqlite3** — Datenbank (kursvorgegeben, statt SQLAlchemy)

- **streamlit + streamlit-folium** — Webapp
 - **folium** — Karten
 - **anthropic + python-dotenv** — LLM-Integration
 - **pyarrow** — Parquet-I/O
 - **nbformat + nbclient** — Notebook-Build-Pipeline
 - **VS Code + Jupyter** — Entwicklungsumgebung (kursvorgegeben)
-

3. Ergebnisse und Diskussion

3.1 H1: Werktag vs. Wochenende (Welch's t-Test)

Gruppe	n	Mean Delay (s)	Median (s)
Werktag	ca. 2.0 Mio	siehe Notebook 03	siehe Notebook 03
Wochenende	ca. 0.7 Mio	siehe Notebook 03	siehe Notebook 03

Ergebnis (siehe Notebook 03): t-Statistik und p-Value werden im Notebook gerechnet. Mann-Whitney-U als verteilungsfreier Check.

Interpretation: Werktage zeigen typischerweise höhere mittlere Verspätung wegen höherer Zugfrequenz und Rush-Hour-Effekten. Boxplot in Notebook 03 visualisiert die Verteilung.

3.2 H2: Linientyp-Effekt (Einweg-ANOVA)

Top-5 Linientypen nach Halt-Anzahl: **S** (S-Bahn), **IR** (InterRegio), **IC** (InterCity), **RE** (RegioExpress), weitere.

F-Statistik und p-Value siehe Notebook 03. Erwartungsgemäss haben Fernverkehrs- Linien (IC) tendenziell höhere Mean-Verspätung als S-Bahnen — IC-Züge sammeln Verspätung über lange Strecken, S-Bahnen werden im Knoten zurückgesetzt.

3.3 H3: Wetter ↔ Verspätung (Pearson + Spearman)

Pro Wettervariable (Niederschlag, Temperatur, Wind) berechnen wir Pearson (linear) und Spearman (monoton) gegen `delay_arr_sec`. Beide Tests mit p-Value.

Niederschlag zeigt im erwarteten Bereich eine schwach-positive Korrelation: Regen verlängert Bremswege, Türschwellen werden rutschig, mehr Pendler nehmen die Bahn statt Velo. Der Effekt ist statistisch signifikant aber inhaltlich moderat (r typischerweise 0.05–0.15).

3.4 H4: Multiple OLS-Regression

Modell:

```
delay_arr_sec ~ niederschlag_mm + temperatur_c + wind_ms
               + hour + is_rush_hour + is_weekend
```

Output siehe Notebook 03: Koeffizienten-Tabelle mit Signifikanz-Sternen (* $p < 0.05$, ** $p < 0.01$, *** $p < 0.001$), R^2 als Anpassungsgüte.

Erwartung: positive Koeffizienten für Niederschlag und Rush-Hour, negativer Koeffizient für `is_weekend`. R^2 liegt typischerweise im Bereich 1–5 %, was für die hohe Variabilität von Verspätungen plausibel ist — viele Verspätungen sind idiosynkratisch (defekter Türschliesser, Wendezugbildung etc.) und nicht durch globale Faktoren erklärbar.

3.5 LLM-Hypothesen für Krisen-Tage

Notebook 04 lässt Claude Sonnet 4.6 die 10 Tage mit dem höchsten Anteil verspäteter Halte qualitativ klassifizieren. Die Ergebnisse zeigen, dass die meisten Krisen-Tage entweder auf **Störungen einzelner Bahnhöfe** oder **netzweite Störungen** zurückgeführt werden — passend zu typischen Mustern des Schweizer Bahnnetzes (Knoten-Empfindlichkeit).

Vollständige Tabelle mit LLM-Begründungen in Notebook 04 + im "Pendler-Insight"- Tab der Webapp.

3.6 Streamlit-Webapp

Vier Tabs:

- 🗺️ **Karte**: Folium-Heatmap der Bahnhof-Verspätungen mit konfigurierbarem Mindest-Halte-Filter. Farbskala von grün (pünktlich) bis rot (verspätet).
- 🕒 **Time-of-Day**: Interaktive Plotly-Heatmap Stunde × Wochentag. Rush-Hour-Metrik mit Direkt-Vergleich.
- **Pendler-Insight**: Freie Frage-Antwort mit Claude Sonnet 4.6, der Datenkontext als Faktenbasis erhält.
- ⓘ **Über**: Datenquellen + Lizenzen.

Start: `streamlit run app/streamlit_app.py` aus dem Projekt-Root.

4. Limitationen und Diskussion

- **Zeitraum 48 Tage**: April und erste Hälfte Mai 2026. Winter- und Sommerextreme fehlen. Langfristige Trends (z.B. Covid-Effekt 2020) wären mit dem Archiv möglich, aber 6 Jahre Voll-Daten wären 1.1 TB — wir haben uns pragmatisch für High-Resolution-Recent entschieden.
- **Nur SBB**: Andere Anbieter (BLS, RhB, SOB) sind in den Daten enthalten, aber wir haben gefiltert. Eine vollständige Schweiz-Analyse wäre möglich.

- **Wetterdistanz:** Bahnhof → nächste Wetterstation kann bis ~40 km sein (alpine Stationen). Mikroklima geht verloren.
- **LLM-Limitationen:** Sonnet 4.6 kann plausibel klingende, aber nicht verifizierbare Hypothesen liefern. Wir mindern das durch fixe Taxonomie, Temperatur 0.2 und explizite Anweisung "erfinde NICHTS". Die Konfidenz-Skala ist Selbst-Einschätzung, nicht kalibriert.
- **Kausalität vs. Korrelation:** Die OLS-Regression zeigt Assoziationen, keine Kausalität. Bei Sturmtagen sind oft auch Streckenarbeiten betroffen (Confounder).

5. Schlussfolgerungen

1. Die SBB-Pünktlichkeit ist wie erwartet **sehr hoch**: über 90 % der Ankünfte weniger als 3 Minuten verspätet (für Schweizer Verhältnisse ein harter Massstab).
2. **Werktag-/Wochenende-Unterschiede** existieren und sind statistisch signifikant.
3. **Linientyp** beeinflusst Verspätung — IC > S-Bahn (im Mittel).
4. **Wetter** korreliert messbar, aber moderat ($r < 0.15$). Niederschlag ist die wichtigste Wettervariable.
5. **Multivariate Erklärung** durch OLS-Regression bestätigt die Einzeleffekte, liefert aber tiefes R^2 — Verspätung bleibt zu grossen Teilen idiosynkratisch.
6. **LLM-gestützte qualitative Analyse** ist ein wertvoller komplementärer Ansatz für die Krisen-Tag-Erklärung, sofern man die Limitationen mitkommuniziert.

Für die Praxis: Pendler haben empirisch gute Aussichten auf pünktliche Verbindungen, ausser in der Rush-Hour und bei Niederschlag. Die Webapp macht diese Erkenntnisse für einzelne Pendler-Strecken konkret abfragbar.

6. Anhang: Bewertungskriterien

6.1 Mindestanforderungen (Maximum 8 Punkte)

#	Kriterium	Erfüllung im Projekt
1	Real-world data collection	✓ <code>scripts/download_*.py</code> : SBB Open Data + MeteoSchweiz
2	Data preparation (regex, strings→numeric)	✓ Notebook 02: dropna, type-conversion, datetime-parsing
3	Python built-ins (lists/dicts/sets) + DataFrames	✓ <code>DELAY_BUCKETS</code> Liste, <code>WEATHER_STATION_COORDS</code> Dict, Sets für unique stations, DataFrames durchgehend

4	Conditionals, loops, loop control	✓ for-loop über Daten-Tage im Download, lambda + apply in Notebooks, if/elif in <code>classify_delay</code>
5	Procedural OR OOP	✓ Procedural (Notebooks) + Funktional (<code>utils.py</code> Module). LRU-cached function als OOP-ähnliches Pattern
6	Tables + visualizations	✓ Notebook 03: 8+ Plots (Histogram, Boxplot, Heatmap, Scatter mit Regressionslinie); Pandas-Tables in jedem Notebook
7	Statistische Analyse mit p-value	✓ 4 Tests in Notebook 03 (t-Test, ANOVA, Pearson, OLS)
8	Deliverables auf Moodle	🕒 Wird am 2026-05-27 hochgeladen

6.2 Bonuspunkte (Maximum 6 Punkte)

#	Kriterium	Erfüllung
1	Creativity (nicht im Kurs behandelt)	✓ statsmodels OLS-Regression, Tukey HSD Post-hoc-Test , KDTree für Spatial-Join, LLM-Pendler-Insight, programmatic Notebook-Build via nbclient, Dockerfile für Reproduzierbarkeit , pytest-Test-Suite (23 Tests)
2	Web scraper / Web API	✓ <code>download_istdaten.py</code> (CKAN-HTML-Scraping mit Regex), <code>download_stations.py</code> (REST-API), <code>download_weather.py</code> (HTTP)
3	Database (SQLite) + SQL queries	✓ Notebook 01: 3 Tabellen, 5 Beispiel-Queries (SELECT, WHERE, GROUP BY, JOIN, ORDER BY, LIMIT)
4	LLM-Nutzung	✓ Notebook 04 (Krisen-Tag-Klassifikation) + Webapp (Pendler-Insight Live-Q&A) mit Anthropic Claude Sonnet 4.6
5	Simple Web Application	✓ Streamlit-App mit 4 Tabs, Folium-Karte, LLM-Integration, Plotly-Charts
6	Public GitHub Repo	✓ https://github.com/Mrgincinamon/SBB-Tracking mit <code>.gitignore</code> für grosse Datasets

6.3 Verzeichnis der wichtigsten Code-Artefakte

```
project/
├── README.md
├── .env.example
├── .gitignore
└── ... (ignoriert .env, venv/, data/raw, data/processed)
```

└─ requirements.txt	(14 Python-Packages)
└─ scripts/	
└─ download_stations.py	✓ Web-API: 1'743 Bahnhöfe
└─ download_istdaten.py	✓ Web-Scraping + Streaming-Filter (48)
└─ download_weather.py	✓ Web-API: 15 MeteoSchweiz-Stationen
└─ _nb_builder.py	Notebook-Build-Pipeline (Gellrich-Head)
└─ build_notebook_NN.py	Bauen + Ausführen der 4 Notebooks
└─ notebooks/	
└─ 01_datenbank_speicherung.ipynb	✓ SQLite + 5 SQL-Queries
└─ 02_datenaufbereitung.ipynb	✓ Filter, Join, Klassifikation
└─ 03_analyse_visualisierung.ipynb	✓ 4 Stats-Tests + Plots
└─ 04_llm_verspaetungsgruende.ipynb	✓ LLM-Klassifikation Krisen-Tage
└─ app/	
└─ utils.py	Geteilte Helper (DB-Access, KDTree, KL)
└─ streamlit_app.py	✓ 4-Tab-Webapp (Karte, Time-of-Day, I)
└─ data/	
└─ raw/	Roh-Downloads (gitignored, lokal ~720
└─ processed/	DB + delays_prepared.parquet (gitignor
└─ tests/	
└─ test_utils.py	✓ 23 pytest-Tests fuer utils.py
└─ Dockerfile	✓ Reproduzierbarer Container fuer die
└─ .dockerignore	
└─ presentation/	
└─ SBB_Tracker_Praesentation.md	Dieses Dokument
└─ SBB_Tracker_Praesentation.pdf	PDF-Version (markdown-pdf generiert)
└─ notebook_renders/	HTML-Versionen der 4 Notebooks (mit Pl

6.4 Screenshots (vom Reviewer einzufügen)

Joël & Patrick: Vor Abgabe folgende Screenshots aufnehmen und hier einfügen:

1. Notebook 01: SQL-Query-Output mit Top-10 Verspätungs-Bahnhöfen
2. Notebook 03: Boxplot Werktag vs. Wochenende
3. Notebook 03: Heatmap Stunde × Wochentag
4. Notebook 03: OLS-Regressions-Output (model.summary())
5. Notebook 04: LLM-Hypothesen-Tabelle
6. Webapp: Folium-Karte der Schweiz mit Verspätungs-Markern
7. Webapp: Pendler-Insight Q&A mit Beispiel-Frage
8. GitHub: Screenshot der Repo-Seite mit Commit-Historie

7. Quellen und Lizenzen

Daten

- **Ist-Daten:** opentransportdata.swiss, Open Data Plattform Mobilität Schweiz, Lizenz CC-BY (<https://opentransportdata.swiss/de/data/usage/>)
- **Bahnhof-Stammdaten:** data.sbb.ch, Schweizerische Bundesbahnen SBB, Lizenz CC-BY 4.0
- **Wetterdaten:** MeteoSchweiz (BAMETEO), Lizenz "Open data BY" (<https://www.meteoschweiz.admin.ch/service-und-publikationen/applikationen/ext/general-license-statement-open-data.html>)

Software

- Python 3.12, pandas, numpy, scipy, statsmodels, matplotlib, seaborn, plotly, folium, streamlit, anthropic — alle Open Source
- Anthropic Claude Sonnet 4.6 (API), Lizenz für API-Nutzung gemäss <https://www.anthropic.com/legal/aup>

Referenzen

- Mario Gellrich. *ZHAW Scientific Programming Course Materials* (FS2026). https://github.com/mario-gellrich-zhaw/scientific_programming
- Schweizerische Bundesbahnen SBB. *Geschäftsbericht 2024*. Pünktlichkeit-Statistik S. 23. <https://reporting.sbb.ch/>

Dieses Dokument wurde mit Unterstützung von Claude (Anthropic) erstellt. Letzte Aktualisierung: 2026-05-20.