

SBB Tracker — Pünktlichkeitsanalyse der Schweizerischen Bundesbahnen

Scientific Programming · FS2026 Joël Hasler & Patrick Ferreira

Datum: 27. Mai 2026 **Modul:** Scientific Programming, ZHAW **Dozent:** Mario Gellrich **GitHub:** <https://github.com/Mrgincinamon/SBB-Tracking>

1. Einleitung

1.1 Hintergrund

Die Schweiz hat eines der dichtesten und pünktlichsten Bahnnetze der Welt. Die Schweizerischen Bundesbahnen (SBB) befördern täglich rund 1.3 Millionen Passagiere und führen über 11'000 Zugfahrten durch. Die offizielle Kundenpünktlichkeit lag 2024 bei 92.5 % — international ein Spitzenwert, aber für eingefleischte Pendler dennoch spürbar verbesserenswert.

Seit Juni 2016 publiziert das Bundesamt für Verkehr (BAV) zusammen mit der Geschäftsstelle KIM die **Ist-Daten** als Open Data: pro Tag eine CSV mit allen Soll-/Ist-Vergleichen jedes Zug-Halts in der Schweiz. Diese Datenmenge (rund 2.5 Millionen Records pro Tag, knapp 500 MB) erlaubt erstmals eine unabhängige, statistisch saubere Analyse der Pünktlichkeit auf Stations-, Linien- und Stundenbasis.

1.2 Problemstellung

Trotz der reichen Datenbasis ist es für einzelne Pendler schwierig, konkrete Antworten auf relevante Alltags-Fragen zu finden:

- Sind Züge am Wochenende wirklich pünktlicher als an Werktagen?
- Welche Bahnhöfe sind Verspätungs-Hotspots?
- Wie stark beeinflusst das Wetter (insbesondere Niederschlag) die Pünktlichkeit?
- Welche Tageszeit ist am riskantesten für termingebundene Reisen?

Bestehende SBB-Statistiken sind Monats-Aggregate ohne Stationsdetail. Die offizielle Pünktlichkeitsangabe „92.5 %“ ist für die individuelle Reiseplanung zu grob.

1.3 Zielsetzung

Dieses Projekt baut eine **End-to-End-Datenpipeline** vom Rohdaten-Download über die SQL-Datenbank zur statistischen Analyse und schliesslich zu einer interaktiven Webapp:

1. **Datenpipeline:** Automatisierter Download von SBB-Ist-Daten + Wetter + Stationen, gefiltert, in SQLite gespeichert.
2. **Statistische Analyse:** Vier Hypothesen-Tests mit p-Value-Reporting (t-Test, ANOVA, Korrelation, multivariate OLS-Regression).
3. **Visualisierung:** Heatmaps, Karten, Verteilungs-Plots nach Best Practice.
4. **Interaktive Webapp:** Streamlit + Folium mit LLM-gestütztem Pendler-Insight.

1.4 Forschungsfragen

1. **H1 (Werktag-Effekt):** Unterscheidet sich die mittlere Verspätung zwischen Werktagen und Wochenende signifikant?
 2. **H2 (Zugtyp-Effekt):** Beeinflusst der Linien-Typ (S-Bahn, IC, IR, RE) die Verspätungsverteilung?
 3. **H3 (Wetter-Korrelation):** Korreliert Niederschlag oder Temperatur mit der Verspätung?
 4. **H4 (Multivariate Erklärung):** Welche Faktoren erklären Verspätung gemeinsam in einem linearen Modell?
-

2. Material und Methoden

2.1 Datenquellen

Datensatz	Quelle	Umfang	Format
Ist-Daten	opentransportdata.swiss (CKAN-Dataset <code>istdaten</code>)	48 Tage, 31. März – 19. Mai 2026 (~3.2 Mio SBB-Zug-Events)	CSV → Parquet
Stationen	data.sbb.ch (Dienststellen-Datensatz)	1'743 aktive Bahnhöfe mit Geo-Koordinaten	CSV
Wetter	MeteoSchweiz Open Data (<code>ch.meteoschweiz.ogd-smn</code>)	15 Stationen, stündlich, ~3'336 h pro Station	CSV → Parquet

Alle Datensätze sind öffentlich (CC-BY-Lizenz, kein API-Key nötig).

2.1.1 Design-Entscheidung: Auflösung vor Zeitspanne

Bei den Ist-Daten stand zu Projektbeginn eine bewusste Wahl an:

- **(a) Lange Zeitspanne, geringe Auflösung** — Wochen-Aggregate über 5+ Jahre (analog zum Covid-Vorlageprojekt). Dataset SBB „Kundenpünktlichkeit-Monat“ hätte rund 130 Zeilen ergeben.
- **(b) Kurze Zeitspanne, hohe Auflösung** — 48 Tage pro Zug-Halt aller SBB-Stationen, mit Wetter-Join pro Stunde.

Wir entschieden uns für **(b)**. Begründung:

Aspekt	(a) Wochen-Aggregate 5 Jahre	(b) Stations-Auflösung 48 Tage
Rohe Daten-Zeilen	~265	2'739'734
Spalten pro Zeile	~5	31 (inkl. Wetter, Zeit-Features)
Datenpunkte gesamt	~1'300	~85'000'000
Stunden-Effekt analysierbar?	nein	ja
Bahnhof-Vergleich möglich?	nein	ja
Wetter-Korrelation pro Stunde?	nein	ja
OLS-Regression mit Kategorien (16 Zugtypen)?	n zu klein	n = 2.74 Mio stabil
Story-Faktor „5 Jahre Trend“	hoch	mittel

Statistisch wären auf (a) drei unserer vier geplanten Tests (ANOVA Linientyp, Pearson Wetter, OLS-Regression) nicht durchführbar gewesen. Variante (b) liefert **rund 17'000× mehr Datenpunkte** als (a) und macht alle vier geplanten statistischen Tests inhaltlich aussagekräftig.

Die Praxis-Limitation von (b) — kein Covid-Vorher-Nachher-Vergleich — adressieren wir transparent in Sektion 4 (Limitationen).

Disk-Realität: Die volle Ist-Daten-Historie 2019–2025 wären 1.1 TB Roh-CSV; unsere 48-Tage-Stichprobe ist **65 MB Parquet nach Filter** (Speed-up Faktor ~10'000 in der Verarbeitung).

2.2 Datenaufbereitung (Notebook 02)

- **Filter:** Nur `produkt_id == 'Zug'` und `betreiber_abk == 'SBB'` (~3 % der Roh-Records); Roh-CSVs nach Filterung gelöscht (Disk-Effizienz).
- **REAL-Filter:** Nur `an_prognose_status == 'REAL'` (echte Messungen, 86 %).
- **Zeit-Features:** Stunde, Wochentag, Wochenende-Flag, Rush-Hour-Flag.
- **Wetter-Join:** Pro Bahnhof nächste Wetterstation via `scipy.spatial.cKDTree` (Euklidisch auf lat/lon); Merge auf `(weather_station, stunde)`.
- **Klassifikation:** Verspätungen in 7 Buckets von "frueh_30+s" bis "extrem_ueber_10min"; binäre Spalte `is_late_3min` (SBB-Definition >3 Min).

2.3 Statistische Methoden (Notebook 03)

Test	Anwendung	scipy/statsmodels-Funktion
Welch's t-Test	Werktag vs. Wochenende	<code>scipy.stats.ttest_ind(..., equal_var=False)</code>
Mann-Whitney-U	Verteilungsfreier Cross-Check zu t-Test	<code>scipy.stats.mannwhitneyu</code>
Einweg-ANOVA	Verspätung nach Linientyp (top 5)	<code>scipy.stats.f_oneway</code>
Pearson-Korrelation	Linear: Wetter ↔ Verspätung	<code>scipy.stats.pearsonr</code>
Spearman-Korrelation	Monoton: Wetter ↔ Verspätung	<code>scipy.stats.spearmanr</code>
Multiple OLS-Regression	Multivariates Erklärungsmodell	<code>statsmodels.formula.api.ols</code>

Signifikanzschwelle $\alpha = 0.05$. Bei multiplen Tests könnte eine Bonferroni-Korrektur auf $\alpha = 0.0125$ ($k = 4$) angewendet werden — wir berichten p-Werte unkorrigiert, da die Effekte deutlich signifikant sind.

2.4 LLM-Integration (Notebook 04 + Webapp)

Anthropic Claude Sonnet 4.6 wird in zwei Kontexten eingesetzt:

1. **Notebook 04**: Qualitative Klassifikation der Top-10 Krisen-Tage. Pro Tag wird ein Kontext-JSON (top betroffene Bahnhöfe, Wetterzusammenfassung, Tageszeit-Pattern) an das Modell übergeben mit fester Taxonomie möglicher Ursachen. Temperatur 0.2 für Reproduzierbarkeit.
2. **Webapp** (Tab "Pendler-Insight"): Freie Frage-Antwort-Funktion. Das Modell erhält statistischen Datenkontext aus dem aktuellen Datensatz und antwortet kurz und auf deutsch.

API-Key wird über `.env`-Datei und `python-dotenv` geladen (gitignored).

2.5 Tech-Stack

- **Python 3.12** (kursvorgegeben)
- **pandas / numpy / scipy / statsmodels** — Data + Statistik
- **matplotlib / seaborn / plotly** — Visualisierungen
- **sqlite3** — Datenbank (kursvorgegeben, statt SQLAlchemy)
- **streamlit + streamlit-folium** — Webapp
- **folium** — Karten
- **anthropic + python-dotenv** — LLM-Integration
- **pyarrow** — Parquet-I/O

- **nbformat + nbclient** — Notebook-Build-Pipeline
- **VS Code + Jupyter** — Entwicklungsumgebung (kursvorgegeben)

3. Ergebnisse und Diskussion

3.1 H1: Werktag vs. Wochenende (Welch's t-Test)

Gruppe	n	Mean Delay (s)
Werktag	1'957'372	50.1
Wochenende	782'362	34.6

Ergebnis: $t = 94.97$, $p < 10^{-300}$ (Welch's t-Test, Heteroskedastizität-tolerant)

Werktag-Züge sind im Mittel **15.5 Sekunden** stärker verspätet als Wochenend-Züge (95%-CI [15.2, 15.8] s). Bei $n \approx 2.7$ Millionen ist der Effekt hochsignifikant — aber die **Effektstärke ist klein** (Cohen's $d \approx 0.12$). Mann-Whitney-U bestätigt verteilungsfrei; ein Robustheits-Test auf **Tagesmitteln ($n=48$)** zeigt, dass der Effekt nicht bloss ein Artefakt der riesigen Stichprobe ist (siehe Notebook 03).

Interpretation: Werktage zeigen erhöhte Verspätung durch höhere Zugfrequenz und Rush-Hour-Effekte. Der Median-Verspätung über alle Tage liegt bei 28 s, das **95. Perzentil bei 181 s** — d.h. nur ~5 % der Halte überschreiten die klassische 3-Minuten-Schwelle.

3.2 H2: Linientyp-Effekt (Einweg-ANOVA)

One-Way ANOVA über 14 Linientypen: $F = 8'450.0$, $p < 10^{-300}$ (höchst signifikant), Effektstärke $\eta^2 \approx 0.039$ (klein). Tukey HSD-Post-hoc-Test in Notebook 03 zeigt, welche Paare sich konkret unterscheiden.

Mittlere Verspätung pro Linientyp (sortiert):

Linientyp	n	Mean Delay (s)	Kategorie
RJX (RailJet eXpress)	1'160	441.6	International
TGV	1'565	347.9	International
EC (EuroCity)	15'639	298.0	International
EXT (Extrazug)	403	197.5	Sonderverkehr

ICE	6'023	136.8	International
TER (TER France)	19'563	65.7	International
SN (S-Nacht)	21'937	54.5	Regionalverkehr
S (S-Bahn)	1'699'562	48.7	Regional
RE (RegioExpress)	158'182	45.2	Regional
R (Regio)	495'983	33.2	Regional
IC (InterCity)	119'879	31.8	Fernverkehr CH
IR (InterRegio)	198'809	27.2	Fernverkehr CH

Interpretation: Internationale Züge (TGV, EC, ICE, RJX) zeigen mit Abstand die höchste Mean-Verspätung — sie sammeln Verspätung über lange Strecken im Ausland und „importieren“ sie in die Schweiz. Innerschweizer Fernverkehr (IC, IR) ist überraschend pünktlich (~30 s) — das Netz funktioniert auf seinen Hauptachsen sehr gut. S-Bahnen liegen im Mittelfeld (49 s), bedingt durch dichte Taktung und enge Knotenanschlüsse.

3.3 H3: Wetter ↔ Verspätung (Pearson + Spearman)

Pro Wettervariable berechnen wir Pearson (linear) und Spearman (monoton) gegen `delay_arr_sec` über $n \approx 2.74$ Mio Beobachtungen:

Variable	Pearson r	Pearson p	Spearman p	Spearman p
Niederschlag (mm)	+0.0218	$< 10^{-286}$	+0.0595	$< 10^{-300}$
Sonnenscheindauer (min)	-0.0368	$< 10^{-300}$	-0.0525	$< 10^{-300}$
Rel. Luftfeuchte (%)	+0.0304	$< 10^{-300}$	+0.0547	$< 10^{-300}$
Temperatur (°C)	-0.0115	$< 10^{-81}$	-0.0334	$< 10^{-300}$
Windgeschwindigkeit (m/s)	-0.0012	0.04	+0.0013	0.03

Interpretation: Niederschlag, Sonne, Feuchte und Temperatur sind durch die enorme Stichprobengrösse **hochsignifikant**; nur **Wind** ist mit $p \approx 0.03$ – 0.04 grenzwertig und überlebt die Bonferroni-Schwelle ($\alpha = 0.0125$) nicht. Entscheidend: Die Effekt-Stärke ist mit $r \approx 0.01$ – 0.06 (95%-CIs in Notebook 03) **inhaltlich trivial** — Signifikanz $\neq$ Relevanz. Niederschlag und Bewölkung (antikorreliert mit Sonnenscheindauer) gehen in die erwartete Richtung: mehr Regen, weniger Sonne → mehr Verspätung. Spearman-p ist durchgängig grösser als Pearson-r, was auf einen monoton-aber-nicht-linearen Zusammenhang hinweist (z.B. extreme Niederschläge wirken überproportional).

Praktische Bedeutung: Wetter erklärt allein nur ~0.3 % der Verspätungs-Varianz.

Pünktlichkeit hängt dominiert von operativen Faktoren ab.

3.4 H4: Multiple OLS-Regression

Modell (statsmodels `smf.ols`, $n = 2'737'961$ — vollständiger Wetter-valider Datensatz, kein Subsample, daher deterministische Schätzer):

```
delay_arr_sec ~ C(is_rush_hour) + C(is_weekend) + C(verkehrsmittel_text)
               + niederschlag_mm + temperatur_c
```

Anpassungsgüte: $R^2 = 0.0430$ (4.30 %), Adj. $R^2 = 0.0430$, $F = 6'470.8$, $p < 10^{-300}$

Wichtigste Koeffizienten (Auswahl, mit 95%-CI in Notebook 03):

Variable	Koeffizient (s)	p-Value	Interpretation
Rush-Hour (True)	+10.4	$< 10^{-300}$	Rush-Hour-Verspätung ~10 s
Wochenende (True)	-12.0	$< 10^{-300}$	Wochenende ~12 s pünktlicher
Niederschlag (pro mm)	+6.32	$< 10^{-214}$	Pro mm Regen +6.3 s
Temperatur (pro °C)	+0.08	$< 10^{-5}$	signifikant, aber praktisch vernachlässigbar
NJ (Nachtzug, vs Referenz)	+357.0	$< 10^{-146}$	Sonderfall: wenige Züge, hohe Streuung
TGV (vs Referenz)	+196.4	$< 10^{-48}$	Internationaler Import-Effekt
EC (vs Referenz)	+146.8	$< 10^{-29}$	dito
S (vs Referenz)	-103.0	$< 10^{-14}$	S-Bahn signifikant pünktlicher

Interpretation:

1. Die **kombinierten Faktoren erklären nur ~4.3 % der Verspätungs-Varianz** — ehrliche Erkenntnis, dass Verspätungen dominant durch unvorhersagbare, idiosynkratische Ereignisse bestimmt sind (Defekte, einzelne Verspätungen, Personalengpässe).
2. Die **drei dominierenden Effekte** sind dennoch konsistent mit der Erwartung: Rush-Hour +10 s, Wochenende -12 s, Niederschlag +6.3 s/mm.
3. Internationale Zugtypen (TGV, EC, NJ) bestätigen den "Import-Effekt".

3.5 LLM-Hypothesen für Krisen-Tage

Notebook 04 lässt Claude Sonnet 4.6 die 10 Tage mit dem höchsten Anteil verspäteter Halte qualitativ klassifizieren. Die Ergebnisse zeigen, dass die meisten Krisen-Tage entweder auf **Störungen einzelner Bahnhöfe** oder **netzweite Störungen** zurückgeführt werden — passend zu typischen Mustern des Schweizer Bahnnetzes (Knoten-Empfindlichkeit).

Vollständige Tabelle mit LLM-Begründungen in Notebook 04 + im "Pendler-Insight"- Tab der Webapp.

3.6 Streamlit-Webapp

Vier Tabs:

-  **Karte**: Folium-Heatmap der Bahnhof-Verspätungen mit konfigurierbarem Mindest-Halte-Filter. Farbskala von grün (pünktlich) bis rot (verspätet).
-  **Time-of-Day**: Interaktive Plotly-Heatmap Stunde × Wochentag. Rush-Hour-Metrik mit Direkt-Vergleich.
- **Pendler-Insight**: Freie Frage-Antwort mit Claude Sonnet 4.6, der Datenkontext als Faktenbasis erhält.
- **i Über**: Datenquellen + Lizenzen.

Start: `streamlit run app/streamlit_app.py` aus dem Projekt-Root.

4. Limitationen und Diskussion

- **Zeitraum 48 Tage**: April und erste Hälfte Mai 2026. Winter- und Sommerextreme fehlen. Langfristige Trends (z.B. Covid-Effekt 2020) wären mit dem Archiv möglich, aber 6 Jahre Voll-Daten wären 1.1 TB — wir haben uns pragmatisch für High-Resolution-Recent entschieden.
- **Nur SBB**: Andere Anbieter (BLS, RhB, SOB) sind in den Daten enthalten, aber wir haben gefiltert. Eine vollständige Schweiz-Analyse wäre möglich.
- **Nicht-Unabhängigkeit der Beobachtungen** (wichtigste statistische Einschränkung): Die 2.7 Mio Halte sind in Zügen, Bahnhöfen und Betriebstagen geschachtelt (Pseudoreplikation) — die effektive Stichprobe ist kleiner als n , weshalb die Roh-p-Werte zu optimistisch sind. Wir begegnen dem mit (a) einem **Tagesmittel-Robustheitstest** (Effekt überlebt mit $n=48$ statt 2.7 Mio) und (b) dem konsequenten Berichten von **Effektstärken** statt nur p-Werten. Eine vollständige Lösung wären Mixed-Effects-Modelle (über den Kursrahmen hinaus).
- **Multiples Testen & grosse Stichprobe**: Bei $k=4$ Test-Familien liegt die Bonferroni-Schwelle bei $\alpha = 0.0125$; **alle Tests überstehen sie** ($p \approx 0$). Die Signifikanz ist also kein Artefakt multiplen Testens — wohl aber Folge der enormen n . Deshalb sind die **Effektstärken** (Cohen's $d \approx 0.12$ = klein, $|r| < 0.04$ = trivial, η^2 klein) die eigentlich

aussagekräftige Grösse.

- **Wetterdistanz:** Bahnhof → nächste Wetterstation kann bis ~40 km sein (alpine Stationen). Mikroklima geht verloren. Die Zuordnung erfolgt über einen $\cos(\text{Breite})$ -korrigierten KDTree (geografisch konsistente Nächste-Nachbar-Suche).
 - **LLM-Limitationen:** Sonnet 4.6 kann plausibel klingende, aber nicht verifizierbare Hypothesen liefern. Wir mindern das durch fixe Taxonomie, Temperatur 0.2 und explizite Anweisung "erfinde NICHTS". Die Konfidenz-Skala ist Selbst-Einschätzung, nicht kalibriert.
 - **Kausalität vs. Korrelation:** Die OLS-Regression zeigt Assoziationen, keine Kausalität. Bei Sturmtagen sind oft auch Streckenarbeiten betroffen (Confounder).
-

5. Schlussfolgerungen

1. Die SBB-Pünktlichkeit ist wie erwartet **sehr hoch**: über 90 % der Ankünfte weniger als 3 Minuten verspätet (für Schweizer Verhältnisse ein harter Massstab).
2. **Werktag-/Wochenende-Unterschiede** existieren und sind statistisch signifikant.
3. **Linientyp** beeinflusst Verspätung — IC > S-Bahn (im Mittel).
4. **Wetter** korreliert messbar, aber moderat ($r < 0.15$). Niederschlag ist die wichtigste Wettervariable.
5. **Multivariate Erklärung** durch OLS-Regression bestätigt die Einzeleffekte, liefert aber tiefes R^2 — Verspätung bleibt zu grossen Teilen idiosynkratisch.
6. **LLM-gestützte qualitative Analyse** ist ein wertvoller komplementärer Ansatz für die Krisen-Tag-Erklärung, sofern man die Limitationen mitkommuniziert.

Für die Praxis: Pendler haben empirisch gute Aussichten auf pünktliche Verbindungen, ausser in der Rush-Hour und bei Niederschlag. Die Webapp macht diese Erkenntnisse für einzelne Pendler-Strecken konkret abfragbar.

6. Anhang: Bewertungskriterien

6.1 Mindestanforderungen (Maximum 8 Punkte)

#	Kriterium	Erfüllung im Projekt
1	Real-world data collection	✓ <code>scripts/download_*.py</code> : SBB Open Data + MeteoSchweiz
2	Data preparation (regex, strings→numeric)	✓ Notebook 02: dropna, type-conversion, datetime-parsing

3	Python built-ins (lists/dicts/sets) + DataFrames	✓ DELAY_BUCKETS Liste, WEATHER_STATION_COORDS Dict, Sets für unique stations, DataFrames durchgehend
4	Conditionals, loops, loop control	✓ for-loop über Daten-Tage im Download, lambda + apply in Notebooks, if/elif in <code>classify_delay</code>
5	Procedural OR OOP	✓ Procedural (Notebooks) + Funktional (<code>utils.py</code> Module). LRU-cached function als OOP-ähnliches Pattern
6	Tables + visualizations	✓ Notebook 03: 8+ Plots (Histogram, Boxplot, Heatmap, Scatter mit Regressionslinie); Pandas-Tables in jedem Notebook
7	Statistische Analyse mit p-value	✓ 4 Tests in Notebook 03 (t-Test, ANOVA, Pearson, OLS)
8	Deliverables auf Moodle	🕒 Wird am 2026-05-27 hochgeladen

6.2 Bonuspunkte (Maximum 6 Punkte)



#	Kriterium	Erfüllung
1	Creativity (nicht im Kurs behandelt)	✓ statsmodels OLS-Regression, Tukey HSD Post-hoc-Test , KDTree für Spatial-Join, LLM-Pendler-Insight, programmatic Notebook-Build via nbclient, Dockerfile für Reproduzierbarkeit, pytest-Test-Suite (23 Tests)
2	Web scraper / Web API	✓ <code>download_istdaten.py</code> (CKAN-HTML-Scraping mit Regex), <code>download_stations.py</code> (REST-API), <code>download_weather.py</code> (HTTP)
3	Database (SQLite) + SQL queries	✓ Notebook 01: 3 Tabellen, 5 Beispiel-Queries (SELECT, WHERE, GROUP BY, JOIN, ORDER BY, LIMIT)
4	LLM-Nutzung	✓ Notebook 04 (Krisen-Tag-Klassifikation) + Webapp (Pendler-Insight Live-Q&A) mit Anthropic Claude Sonnet 4.6
5	Simple Web Application	✓ Streamlit-App mit 4 Tabs, Folium-Karte, LLM-Integration, Plotly-Charts
6	Public GitHub Repo	✓ https://github.com/Mrgincinamon/SBB-Tracking mit <code>.gitignore</code> für grosse Datasets

6.3 Verzeichnis der wichtigsten Code-Artefakte

project/	
├─ README.md	
├─ .env.example	
├─ .gitignore	(ignoriert .env, venv/, data/raw, data/processed)
├─ requirements.txt	(14 Python-Packages)
├─ scripts/	
│ └─ download_stations.py	✓ Web-API: 1'743 Bahnhöfe
│ └─ download_istdaten.py	✓ Web-Scraping + Streaming-Filter (480000 Datensätze)
│ └─ download_weather.py	✓ Web-API: 15 MeteoSchweiz-Stationen
│ └─ _nb_builder.py	Notebook-Build-Pipeline (Gellrich-Head)
│ └─ build_notebook_NN.py	Bauen + Ausführen der 4 Notebooks
├─ notebooks/	
│ └─ 01_datenbank_speicherung.ipynb	✓ SQLite + 5 SQL-Queries
│ └─ 02_datenaufbereitung.ipynb	✓ Filter, Join, Klassifikation
│ └─ 03_analyse_visualisierung.ipynb	✓ 4 Stats-Tests + Plots
│ └─ 04_llm_verspaetungsgruende.ipynb	✓ LLM-Klassifikation Krisen-Tage
├─ app/	
│ └─ utils.py	Geteilte Helper (DB-Access, KDTree, KNeighborsClassifier)
│ └─ streamlit_app.py	✓ 4-Tab-Webapp (Karte, Time-of-Day, IHR, Krisen-Tage)
├─ data/	
│ └─ raw/	Roh-Downloads (gitignored, lokal ~720 MB)
│ └─ processed/	DB + delays_prepared.parquet (gitignored)
├─ tests/	
│ └─ test_utils.py	✓ 23 pytest-Tests fuer utils.py
├─ Dockerfile	✓ Reproduzierbarer Container fuer die Entwicklung
├─ .dockerignore	
└─ presentation/	
└─ SBB_Tracker_Praesentation.md	Dieses Dokument
└─ SBB_Tracker_Praesentation.pdf	PDF-Version (markdown-pdf generiert)
└─ notebook_renders/	HTML-Versionen der 4 Notebooks (mit Plotly)


6.4 Screenshots und Plots

6.4.1 Verspätungs-Verteilung (Notebook 03, alle Halte)




Linkes Panel: Histogramm der Ankunftsverspätung (geclippt $-60 \dots +600$ s, Spike am rechten Rand = Verspätungen ≥ 10 min). Rechtes Panel: Boxplot ohne Outlier. Beobachtung: Median knapp über 0, deutlicher Rechts-Skew.

6.4.2 Linientyp-Boxplot (Notebook 03, Top-5)



Boxplot der 5 häufigsten Linientypen. S-Bahn (S) hat den höchsten Median, gefolgt von RE; IR und IC sind besser. Streuung in allen Gruppen ähnlich gross.


6.4.3 Time-of-Day-Heatmap (Notebook 03)



Heatmap: Dienstag 0–3 Uhr ist auffällig (dunkelste Zellen), Werktag-Abend 17–22 Uhr durchgehend erhöht, Wochenenden tendenziell pünktlicher.

6.4.4 Streamlit-Webapp: Karte

6.4.5 Streamlit-Webapp: Time-of-Day



6.4.6 Streamlit-Webapp: Pendler-Insight (LLM)



Live-Q&A-Interface mit Claude Sonnet 4.6. Im Vorab geladene Tabelle zeigt die 10 Krisen-Tage mit LLM-klassifizierter Ursache und Konfidenz-Skala.

6.4.7 Top-10 Bahnhöfe mit höchster Mean-Verspätung

Rang	Station	n	Mean Delay (s)
1	Buchs SG	2'405	195.5
2	St. Margrethen SG	2'311	169.2
3	Basel St. Johann	1'523	127.2
4	Hünenberg Zythus	3'111	115.8
5	Stabio	3'040	110.4
6	Neuhausen Rheinfal	2'568	107.8
7	Zug Chollermüli	6'232	107.4
8	Cham Alpenblick	6'234	105.1
9	Zug Schutzengel	6'053	103.9
10	Paradiso	7'522	101.7

Auffällig: Grenzbahnhöfe (Buchs SG, St. Margrethen SG zu Vorarlberg/Liechtenstein, Basel St. Johann zur DB, Stabio/Paradiso zum TPL Tessin) dominieren — der "Import-Effekt" aus dem internationalen Verkehr ist auch geografisch sichtbar.

7. Quellen und Lizenzen

Daten

- **Ist-Daten:** opentransportdata.swiss, Open Data Plattform Mobilität Schweiz, Lizenz CC-BY (<https://opentransportdata.swiss/de/data/usage/>)
- **Bahnhof-Stammdaten:** data.sbb.ch, Schweizerische Bundesbahnen SBB, Lizenz CC-BY 4.0
- **Wetterdaten:** MeteoSchweiz (BAMETEO), Lizenz "Open data BY" (<https://www.meteoschweiz.admin.ch/service-und-publikationen/applikationen/ext/general-license-statement-open-data.html>)

Software

- Python 3.12, pandas, numpy, scipy, statsmodels, matplotlib, seaborn, plotly, folium,

streamlit, anthropic — alle Open Source

- Anthropic Claude Sonnet 4.6 (API), Lizenz für API-Nutzung gemäss <https://www.anthropic.com/legal/aup>

Referenzen

- Mario Gellrich. *ZHAW Scientific Programming Course Materials* (FS2026). https://github.com/mario-gellrich-zhaw/scientific_programming
- Schweizerische Bundesbahnen SBB. *Geschäftsbericht 2024*. Pünktlichkeit-Statistik S. 23. <https://reporting.sbb.ch/>

Dieses Dokument wurde mit Unterstützung von Claude (Anthropic) erstellt. Letzte Aktualisierung: 2026-05-20.